

Universidade Federal de Pernambuco

Centro de Ciências Exatas e da Natureza - Departamento de Estatística

Tatiana Alejandra Moreno Avila

TÓPICOS ESPECIAIS EM ESTATÍSTICA COMPUTACIONAL

Relatório trabalho final - Classificação do Risco Cardiovascular

Introdução

No contexto das doenças cardiovasculares, estas representam a principal causa de mortalidade no mundo, correspondendo a aproximadamente 31% das mortes, segundo a Organização Mundial da Saúde. A prevalência dos diferentes fatores de risco para o desenvolvimento de doenças cardiovasculares tem aumentado ao longo dos anos, devido às mudanças nos estilos de vida e hábitos alimentares que a sociedade tem experimentado.

Este estudo busca caracterizar o perfil cardiovascular de um banco de dados proveniente do projeto “Corações de Baependi”, desenvolvido na Universidade de São Paulo, cujo objetivo geral é identificar determinantes associados a doenças cardiovasculares. Através de um modelo preditivo de rede neural totalmente conectada, busca-se, neste trabalho, identificar padrões e correlações entre variáveis antropométricas e bioquímicas associadas ao risco cardiovascular.

Fundamentos Teóricos e Metodológicos

Os modelos de redes neurais binárias buscam prever uma variável categórica, sendo no nosso caso o risco cardiovascular. Essa variável é definida pelos parâmetros apresentados em diversas pesquisas, levando em conta variáveis como colesterol total (CTOTAL), LDL (CLDL), HDL (CHDL), triglicerídeos (Triglic) e idade, as quais possuem correlação associada ao risco cardiovascular. A partir delas, obtemos nossa variável de interesse, “Risco”, que é definida entre 0 e 1, sendo 0 igual a “possui risco” e 1 igual a “não possui risco”.

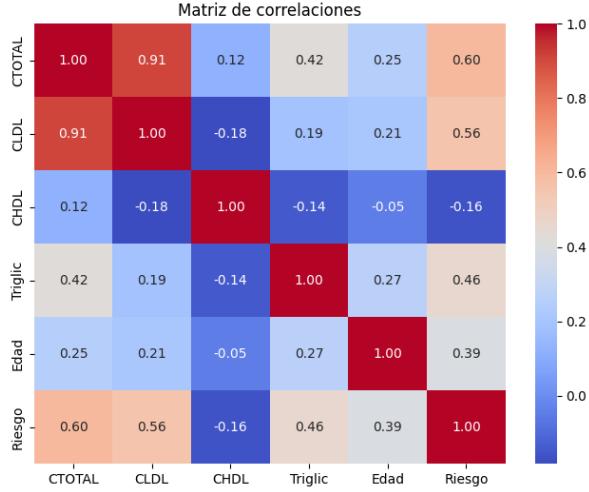


Figure 1: Matriz de Correlação

O objetivo deste análise é modelar a variável resposta $Y = \text{Risco}$, onde: $Y = 0$: Baixo risco e $Y = 1$: Alto risco.

Portanto, modelamos a probabilidade condicional: $P(Y = 1 | \mathbf{X}) = f(\mathbf{X})$,

onde \mathbf{X} representa as variáveis preditoras bioquímicas e antropométricas.

A rede neural utilizada aproxima:

$$\hat{y} = \sigma(W_3 \cdot \text{ReLU}(W_2 \cdot \text{ReLU}(W_1 \mathbf{X} + b_1) + b_2) + b_3)$$

onde: a função ReLU é dada por $\text{ReLU}(z) = \max(0, z)$, a função de ativação sigmoide é $\sigma(z) = \frac{1}{1+e^{-z}}$, e a função de perda para classificação binária utilizada é a **Binary Crossentropy**:

$$L = -[y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})]$$

Aplicação

Esta base de dados conta com um número de 1587 registros e possui 12 variáveis explicativas, das quais algumas são utilizadas para determinar a variável de risco cardiovascular, conforme estipulado pela Organização Mundial da Saúde.

Para realizar a aplicação, primeiro realizamos uma análise exploratória da base de dados, pois ela conta com as seguintes variáveis de medidas antropométricas e bioquímicas.

Tabela medidas antropométricas e bioquímicas

Medida	Sexo	Edad	IMC	BAI	Cintura
count	1587.000000	1587.000000	1.587000e+03	1.587000e+03	1587.000000
mean	1.567738	44.097669	2.136145e+14	2.218316e+14	87.263390
std	0.495546	16.999219	9.103282e+13	9.974663e+13	12.317006
min	1.000000	17.000000	2.080000e+01	1.936997e+11	54.000000
25%	1.000000	30.000000	1.961328e+14	1.707279e+14	78.000000
50%	2.000000	43.000000	2.291299e+14	2.213687e+14	86.000000
75%	2.000000	56.000000	2.650850e+14	2.758850e+14	95.000000
max	2.000000	98.000000	4.919502e+14	9.645401e+14	144.000000

Medida	Cadera	CVLDL	Triglic	CTOTAL	CLDL
count	1587.000000	1587.000000	1587.000000	1587.000000	1587.000000
mean	97.830498	26.628859	131.672968	180.768179	98.570762
std	9.988689	18.842513	70.381810	47.410663	43.763440
min	51.000000	3.200000	34.200000	84.700000	9.700000
25%	92.000000	16.700000	83.600000	145.100000	67.050000
50%	97.000000	22.400000	112.300000	174.700000	94.300000
75%	103.000000	31.750000	158.500000	210.400000	125.800000
max	160.000000	526.000000	639.000000	435.000000	390.100000

Medida	CHDL
count	1587.000000
mean	55.901701
std	15.753750
min	13.000000
25%	45.100000
50%	53.900000
75%	65.950000
max	128.400000

Nossa variável de risco divide nossa base de dados em: Alto risco (1): 429 pacientes, Baixo risco (0): 1158 pacientes e Proporção: 27,03% de alto risco. Em seguida, para treinar adequadamente o modelo, as variáveis CTOTAL, CLDL, CHDL e Triglic são removidas, pois foram utilizadas para definir a variável de risco. Isso é feito com o objetivo de permitir que o modelo identifique padrões entre os pacientes para classificá-los em uma das duas categorias.

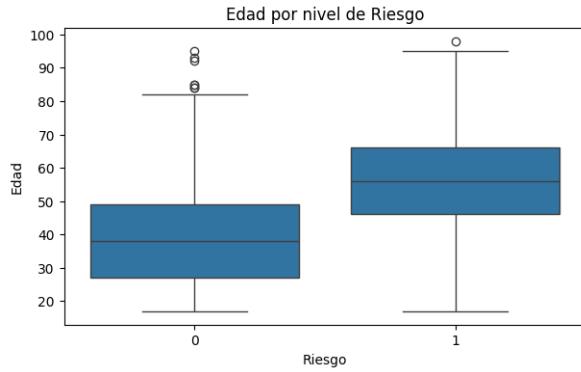


Figure 2: Comparaçao da idade dado o risco

No gráfico anterior, podemos observar uma diferença entre as idades de ambos os grupos, sendo mais comum que os pacientes com baixo risco sejam mais jovens do que os pacientes com alto risco.

Depois de realizar o respectivo escalonamento e padronização das variáveis, o modelo de rede neural binária é definido da seguinte maneira:

Estrutura do Modelo

```
Model: "sequential"
```

Layer (type)	Output Shape	Param #
dense (Dense)	(None, 64)	512
dropout (Dropout)	(None, 64)	0
dense_1 (Dense)	(None, 32)	2,080
dropout_1 (Dropout)	(None, 32)	0
dense_2 (Dense)	(None, 16)	528
dense_3 (Dense)	(None, 1)	17

```
Total params: 3,137 (12.25 KB)
```

```

Trainable params: 3,137 (12.25 KB)
Non-trainable params: 0 (0.00 B)

```

Após treinar o modelo, obtemos o seguinte desempenho em sua respectiva avaliação do modelo.

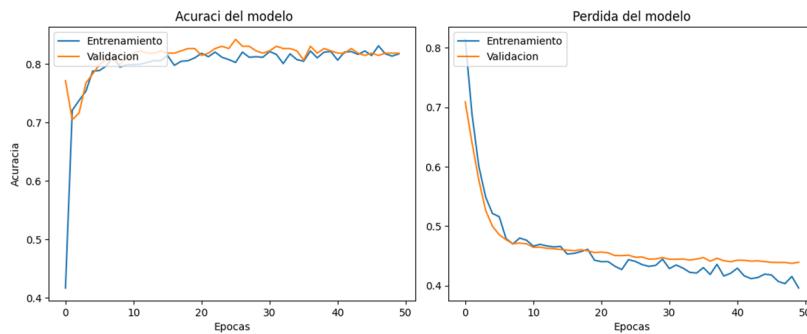


Figure 3: Avaliação - Accuracy e Loss

Notemos que este modelo apresenta um bom desempenho, o que é evidenciado pelas curvas de accuracy e loss, com valores de 0,8176 e 0,4348, respectivamente. Não há sinais de overfitting e o modelo atinge um nível satisfatório, o que fica ainda mais claro na seguinte matriz de confusão.

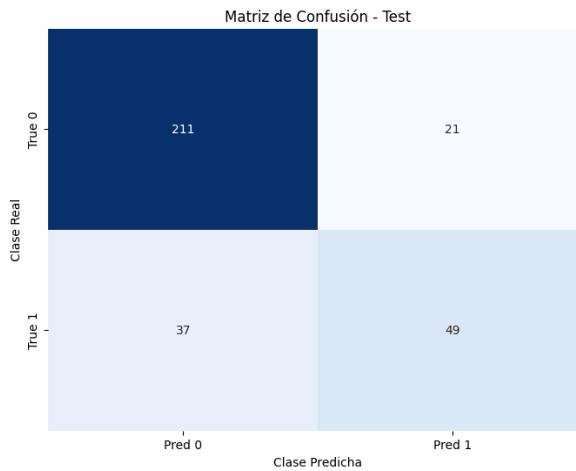


Figure 4: matriz de confusão

	precision	recall	f1-score	support
Clase 0	0.85	0.91	0.88	232
Clase 1	0.70	0.57	0.63	86
accuracy			0.82	318
macro avg	0.78	0.74	0.75	318
weighted avg	0.81	0.82	0.81	318

Este modelo apresenta um melhor desempenho na identificação de pacientes com baixo risco e, para os pacientes de alto risco, possui um desempenho moderado. Além disso, o modelo demonstra capturar padrões relevantes das variáveis.

Conclusão

Este modelo de rede neural apresenta um comportamento razoavelmente bom e, com base nos resultados obtidos, mostra-se uma proposta satisfatória para determinar padrões na classificação dos pacientes, permitindo assim identificar quais outros fatores podem influenciar no risco de desenvolver alguma doença cardiovascular. Sendo assim, constitui uma possível ferramenta de apoio em pesquisas de saúde e genética, capaz de classificar de maneira aceitável, a partir de medidas antropométricas e bioquímicas, todos os padrões que levam a um risco elevado, possibilitando análises exploratórias clínico-descritivas mais rigorosas.

Referências

- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning*. Springer.
- Organização Mundial da Saúde (OMS). Relatórios sobre doenças cardiovasculares.